

- Một Giả thiết trong thống kê là gì ?
- tại sao cần kiểm định giả thiết thống kê ? (hypothesis testing)
- Ý tưởng kiểm định ra sao ? Các bước thực hiện thế nào ?

Video 1 : <https://www.youtube.com/watch?v=0oc49DyA3hU>
(15')

← tình huống 1 : đầu - 4:40'
tình huống 2 : 9:00'
lỡ quên thuật ngữ "giả thiết gốc"
(null hypothesis)

Video 2 : lỡ quên thuật ngữ "giả thiết đối" (alternative hypothesis)
https://www.youtube.com/watch?v=5koKb5B_YWo (1,54' - 8:50')
(7')

⊗ Đại lượng giúp chúng ta kiểm định giả thiết thống kê và đưa ra kết luận

. Mức ý nghĩa (significant level)

. giá trị p (p-values)

p-values là gì
và mức ý nghĩa

<https://www.youtube.com/watch?v=vemZtEM63GY>

(11')

cách tính p-values

qua các tình huống.

<https://www.youtube.com/watch?v=JQc3yx0-Q9E>

(25') !!!

quan trọng

I kiểm định giả thiết thống kê cho tỷ lệ tổng thể của 1 tổng thể.

Ví dụ vấn đề quan tâm:

Trong những năm trước đó, có 52% cha mẹ tin rằng các thiết bị điện tử và mạng xã hội là nguyên nhân gây ra chứng mất ngủ ở tuổi vị thành niên.

Ngày nay, liệu có nhiều cha mẹ tin rằng các thiết bị điện tử và mạng xã hội gây ra chứng mất ngủ ở tuổi vị thành niên này hay không ?

Phân tích:

- Tổng thể: cha mẹ có con ở tuổi vị thành niên (10 - 19 tuổi)
- Tham số ta quan tâm: tỷ lệ tổng thể (p) của cha mẹ tin rằng thiết bị điện tử và mạng xã hội gây ảnh hưởng đến chứng mất ngủ ở con của họ

Mục đích: Chúng ta *kiểm định* rằng *liệu có sự tăng đáng kể phần trăm* cha mẹ *tin rằng* thiết bị điện tử và mạng xã hội gây ảnh hưởng đến chứng mất ngủ ở con của họ

Chú ý: Thực tế khi kiểm định bất kỳ giả thiết thống kê nào, chúng ta nên chọn giả thiết mà ta muốn kiểm định trước khi thu thập dữ liệu để tránh ảnh hưởng đến nhận định giả thiết mà ta muốn kiểm tra.

⊗ Bước 1: Thiết lập giả thiết thống kê

- Giả thiết gốc cần kiểm định
(null hypothesis)

$H_0: p = 0.52$ giả thiết cho
"tỷ lệ tổng thể"
cần được
kiểm định

- Giả thiết đối (alternative hypothesis) $H_1: p > 0.52$

↑
vì ta muốn tìm hiểu xem tỷ lệ
đó có từng đáng kể hay không.

p = là tỷ lệ tổng thể của tất cả cha mẹ có con tuổi vị thành
niên mà tin rằng thiết bị điện tử và mạng xã hội gây thiếu ngủ

• Xác định mức ý nghĩa thống kê (significant level)

$$\alpha = 0.05$$

⊗ bước 2: kiểm tra dữ liệu và tính giá trị thống kê kiểm định (test statistic)

khảo sát mẫu ngẫu nhiên (random sample) của 1018 cha mẹ mà có con tuổi vị thành niên, có 56% tin rằng thiết bị điện tử và mạng xã hội gây ra chứng thiếu ngủ của con họ. ($\hat{p} = 0.56$ là tỷ lệ mẫu)

⊗ khi tiến hành lấy dữ liệu khảo sát cần đảm bảo

- Lấy mẫu ngẫu nhiên (random samples)

- cỡ mẫu đủ lớn để đảm bảo tỷ lệ mẫu xấp xỉ pp chuẩn được

(chẳng hạn trong mẫu có ít nhất 10 người trả lời có ($np \geq 10$))

và có ít nhất 10 người trả lời không ($n(1-p) \geq 10$)

(thay p bởi $p_0 = 0.56$, cần np_0 và $n(1-p_0) \geq 10$)

$1018 \cdot 0.56 \geq 10$
 $1018 \cdot 0.44 \geq 10$

$$= \frac{\text{tính giá trị thống kê kiểm định (test statistic)}}{\text{ước lượng tốt nhất} - \text{ước lượng được giả thiết}}$$

ước lượng "sai số" (standard error)

• ước lượng tốt nhất của tỷ lệ tổng thể là tỷ lệ mẫu $\hat{p} = 0.56$

ước lượng tỷ lệ giả thiết thống kê H_0 (được giả sử là đúng) $p_0 = 0.52$

• Định lý GHTT : $\hat{p} \sim N(\mu, \frac{\sigma^2}{n})$ với $\mu = p$ và nào đó ta ko biết chỉ xác giá trị thực của nó
 $\sigma^2 = p(1-p)$

"Sai số" (standard error) của $\hat{p}$ là $\sqrt{\frac{p(1-p)}{n}}$

→ dưới giả sử qthiết H_0 đúng thì "sai số" của $\hat{p}$ là $\sqrt{\frac{p_0(1-p_0)}{n}}$

$$Z := \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{0.56 - 0.52}{\sqrt{\frac{0.52 \times 0.48}{1018}}} = \frac{0.04}{0.0157} \approx 2.555 \quad (\text{z-test statistic})$$

cách hiểu về giá trị thống kê kiểm định Z (Z-test statistic)

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = 2.555$$

$\sqrt{\frac{p_0(1-p_0)}{n}}$ được gọi là "null standard error"

(standard error under null hypothesis)

Đlý GHTT + tiết trước giải thích

$$\hat{p} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$


$\mu = p$ nào đó $= p_0$ (gsử H_0 đúng)

$$\sigma^2 = p(1-p) = p_0(1-p_0)$$


$$\Rightarrow Z \sim N(0,1)$$

$Z = 2.555$ nghĩa là tỷ lệ mà ta quan sát được từ mẫu có khoảng cách lớn hơn tỷ lệ tổng thể khi ta gsử H_0 đúng một đoạn bằng 2.555 độ lệch chuẩn (dưới giả thiết thống kê H_0)


⊗ bước 3 : tính p-value từ giá trị thống kê kiểm định (test statistic)



tính tiên
 $\hat{p} - p_0 \sim N(0, \frac{\sigma^2}{n})$
 $\sigma^2 = p_0(1-p_0)$



"chuẩn hóa"
 $\frac{\hat{p} - p_0}{\sigma / \sqrt{n}} \sim N(0, 1)$



$$H_1 : p > 0.52$$

$$Z \sim N(0, 1) \rightarrow \text{trabảng } P(Z > 2.555) = 0.0053$$

$$p\text{-value} = 0.0053$$

⊗ Bước 4: so sánh p -value với mức ý nghĩa (significant level α) và đưa ra quyết định "bác bỏ" hay "Không thể bác bỏ" giả thiết gốc H_0

$$p\text{-value} = 0.0053 < \text{mức ý nghĩa } \alpha = 0.05$$

→ "bác bỏ" (reject) giả thiết gốc H_0 : $p = 0.52$

→ chúng ta có thể ủng hộ giả thiết đối, nghĩa là tỷ lệ (tổng thể) cha mẹ có con tuổi vị thành niên mà tin rằng thiết bị điện tử và mạng xã hội gây ra chứng thiếu ngủ cho con họ lớn hơn 52%.

TỔNG KẾT:

- Kiểm định giả thiết thống kê dùng để kiểm định một giả thiết về tham số tổng thể nào đó mà ta quan tâm (ví dụ, tỷ lệ tổng thể, trung bình tổng thể, ...)
- *Các bước thực hiện kiểm định giả thiết thống kê (hypothesis testing)*
 - Bước 1: Phát biểu giả thiết (giả thiết gốc H_0 và giả thiết đối H_1) và xác định mức ý nghĩa (significant level)
 - Bước 2: Kiểm tra giả thiết của dữ liệu (random sample, xấp xỉ chuẩn hay xấp xỉ phân phối nào), lấy thông tin từ dữ liệu và tính giá trị thống kê kiểm định (test statistic)
 - Bước 3: Chuyển đổi giá trị thống kê kiểm định (test statistic) sang p-value
 - Bước 4: So sánh giá trị p-value với mức ý nghĩa và đưa ra quyết định.

Z-test statistic

Cho bài toán kiểm định về tỷ lệ tổng thể

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

$$T = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \rightarrow \text{tra bảng PP } t$$

$\hat{p}$ - tỷ lệ mẫu

p_0 - tỷ lệ tổng thể dưới giả sử H_0 đúng

n - cỡ mẫu (số quan sát)

n đủ lớn (> 30) - xấp xỉ χ^2 PP chuẩn

$n < 30 \sim$ xấp xỉ PP t

tại sao chỉ có "bác bỏ" (reject)

một giả thiết thống kê

và "không thể bác bỏ" (fail to reject)

mà không có "chấp nhận" (accept)

https://www.youtube.com/watch?v=5koKb5B_YWo

(5:45 - 7:54)

vì có rất nhiều "khả năng" để kiểm định đến nỗi ta không biết chính xác ta "chấp nhận" giả thiết nào là đúng.

II) Kiểm định giả thiết thống kê cho kỳ vọng tổng thể²

VD tình huống : qua một số kinh nghiệm quan sát trước đó (ví dụ tiết trước ta thấy khoảng cách trung bình nhào lộn của người lớn là ≈ 82 inches), Ta quan tâm câu hỏi giả thiết

" Vậy khoảng cách trung bình nhào lộn của người lớn có lớn hơn 80 inches ? "



↓
"giả thiết" mà ta không biết đúng hay không.

Tìm "bằng chứng, lập luận" để bác bỏ giả thiết này hay không đủ bằng chứng để bác bỏ giả thiết này.

phân tích vấn đề:

- Tổng thể (population): tất cả người lớn
- Tham số (tổng thể) ta quan tâm: trung bình tổng thể khoảng cách nhào lộn của tất cả người lớn (ký hiệu μ)

Ta tiến hành kiểm tra giả thiết trên dựa trên một mẫu các giá trị đo khoảng cách nhào lộn của 25 người lớn.

(.giả thiết được đặt ra dựa trên kinh nghiệm trước đó và xuất phát từ mục đích ta quan tâm.

. giả thiết (thống kê) được đưa ra trước khi lấy số liệu để kiểm định để tránh tình chủ quan (thiên vị) khi đưa ra giả thiết.)

(*) Bước 1: Xác định giả thiết gốc (null hypothesis, H_0)
 { giả thiết đối (alternative hypothesis, H_1)

- giả thiết gốc : kỳ vọng (giá trị trung bình) tổng thể khoảng cách nhào lộn của người lớn (μ) là 80 inches
- giả thiết đối : trung bình tổng thể **lớn hơn** 80 inches .

Ký hiệu :

$$H_0: \mu = 80$$

$$H_1: \mu > 80$$

μ là trung bình tổng thể khoảng cách nhào lộn của tất cả người lớn

?? ? Cần bao nhiêu bằng chứng để thuyết phục bác bỏ giả thiết H_0 và ủng hộ H_1

mức ý nghĩa (significant level) α :

$$\alpha = 0.05$$

(video đầu slides)

⊗ Bước 2: thu thập, xử lý và kiểm tra dữ liệu ; kiểm tra giả thiết của mẫu dữ liệu, tính giá trị thống kê kiểm định (test statistic)

```
df.describe()["CWDistance"]
```

count	25.000000
mean	82.480000
std	15.058552
min	63.000000
25%	70.000000
50%	81.000000
75%	92.000000
max	115.000000

Name: CWDistance, dtype: float64

- . cỡ mẫu (số quan sát) : $n = 25$ (count)
- . khoảng cách nhỏ nhất min = 63 inch
khoảng cách lớn nhất max = 115 inch
- . khoảng cách trung bình mean = 82.48
và độ lệch chuẩn Std = 15.06

Kiểm tra giả thiết (yêu cầu) của mẫu dữ liệu:

- Mẫu dữ liệu được lấy một cách ngẫu nhiên hay không (random sample): mẫu có đại diện cho tổng thể, xác suất mỗi người được chọn để khảo sát là như nhau
- Phân phối của khoảng cách nhào lộn của mỗi người lớn có phân phối chuẩn (điều này không quan trọng lắm nếu cỡ mẫu đủ lớn, thì giá trị trung bình khoảng cách nhào lộn có thể xấp xỉ chuẩn (Định lý giới hạn trung tâm) (Cỡ mẫu 25 cũng có thể ok để xấp xỉ phân phối chuẩn (chính xác hơn là phân phối t, cùng hình dạng cái chuông, đối xứng, khác mỗi phần đuôi của 2 bên phân phối dày hơn phân phối chuẩn)

- Giá trị trung bình mẫu khảo sát là 82.48 inches

Nó có thật sự "lớn hơn đáng kể" so với giá trị trung bình tổng thể mà ta giả thiết 80 inches ?

2.48 inch là lớn hay nhỏ? Nếu chúng ta thực hiện lại thực nghiệm của mình, chúng ta sẽ nhận được các giá trị trung bình mẫu khác nhau ngay cả khi giả thuyết gốc H_0 là đúng và giá trị trung bình thực sự tổng thể là 80 inch. Các giá trị trung bình mẫu sẽ thay đổi xung quanh giá trị trung bình thực, đôi khi cao hơn, đôi khi thấp hơn.

Vì vậy, sự khác biệt mà chúng ta đang thấy ở đây 82,48 inch là đáng kể hay nó chỉ là một giá trị phản ánh sự biến thiên sự phân tán tự nhiên khi làm thực nghiệm? Vì vậy, để đo mức độ xa của trung bình mẫu so với giá trị trung bình thực đó, chúng ta cần biết "sai số" (standard error) của giá trị trung bình mẫu và từ đó tính được **"giá trị thống kê kiểm định" (test statistic)**

$$\text{Standard error của trung bình mẫu} = \frac{\sigma}{\sqrt{n}}$$

(DLGHTT) σ - độ lệch chuẩn tổng thể
Không biết

$$\xrightarrow{\text{ước lượng xấp xỉ}} \text{Standard error} = \frac{s}{\sqrt{n}}$$

s là độ lệch chuẩn của mẫu
(ước lượng cho σ)

- tính giá trị thống kê kiểm định (đo khoảng cách "bao xa" giữa giá trị trung bình mẫu và giá trị trung bình tổng thể giả thiết ở giá thiết gốc H_0)
- giả sử phân phối của trung bình mẫu là pp chuẩn

$$t = \frac{\text{ước lượng tốt nhất} - \text{giá trị ở giả thiết gốc } H_0}{\text{ước lượng "sai số"}}$$

$$t = \frac{\bar{X} - 80}{\frac{S}{\sqrt{n}}} = \frac{82.48 - 80}{\frac{15.06}{\sqrt{25}}} = 0.82$$

Ý nghĩa: Giá trị thống kê kiểm định (test statistic) $t=0.82$ cho chúng ta thấy rằng giá trị trung bình mẫu của chúng ta chỉ lớn hơn giá trị trung bình tổng thể 80 inch mà ta giả thiết một khoảng bằng 0.82 lần "sai số" (standard error được ước lượng) (Chú ý: ta luôn giả định giả thiết gốc H_0 đúng và tìm bằng chứng bác bỏ hay không thể bác bỏ)

Khoảng cách này là phổ biến dễ xảy ra hay bất thường hiếm xảy ra $\rightarrow$ ta chuyển giá trị thống kê kiểm định này sang giá trị "xác suất" tương ứng (p-values sẽ cho ta biết là khoảng cách đó là phổ biến hay bất thường)

⊗ Bước 3 : Xác định giá trị p (p -values)


- Xác định giá trị p để trả lời cho câu hỏi :


" Nếu giả thiết gốc H_0 là đúng , thì giá trị thống kê kiểm định $t = 0.82$ là "đủ bất thường " để bác bỏ H_0 hay không ? "

- Nếu giả thiết H_0 đúng, thì giá trị thống kê kiểm định t sẽ xấp xỉ phân phối t với bậc tự do $df = 25 - 1 = 24$.

p -value = xác suất phần màu xanh = 0.21
(tính máy online)

Giải thích vì sao chỉ có phần màu xanh mà không phải đối xứng 2 phía trang sau





$$t = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim t(24) \quad \rightarrow \quad \bar{X} = \mu + 0.82 \frac{\sigma}{\sqrt{n}} \approx \mu + 0.82 \frac{s}{\sqrt{n}}$$

0.82

Nhắc lại ý nghĩa và cách tính p-value (video đầu slides): Xác suất thấy giá trị thống kê kiểm định (test statistic) $t = 0.82$ này và những giá trị t “hiếm hơn” (more extreme) dưới giả sử giả thiết thống kê H_0 đúng. Nghĩa là khoảng cách từ trung bình mẫu đến giá trị trung bình thực như vậy có “phổ biến” hay “hiếm (extreme)” không + Giả thiết đối H_1 mà ta quan tâm là khoảng cách trung bình tổng thể > 80 inch nên ta chỉ quan tâm phần xác suất phần gạch chéo (1 phía bên phải)

Nếu giả thiết đối là khoảng cách trung bình tổng thể là < 80 thì ta quan tâm 1 phía bên trái. Nếu giả thiết đối là khác 80 thì ta quan tâm 2 phía.

⊗ Bước 4: Đưa ra quyết định về giả thiết gốc H_0
bác bỏ H_0 (reject) → giả thiết đối H_1 được ủng hộ
< không đủ bằng chứng để bác bỏ H_0 (fail to reject)
↳ (những ko có nghĩa là chấp nhận / ủng hộ giả thiết đó)

$p\text{-value} = 0.21 > \text{mức ý nghĩa } \alpha = 0.05$
(significant level)

Nghĩa là giá trị thống kê kiểm định (test statistic) $t = 0.82$ không nằm trong 5% ít xảy ra (xem lại video đầu slides). Nói cách khác, là khoảng cách từ trung bình mẫu 82.48 đến trung bình tổng thể 80 inch (ta giả sử giả thiết H_0 đúng) không nằm trong 5% "hiếm" (extreme).

Do đó, kết luận: bằng chứng của chúng ta yếu (không đủ bằng chứng) để bác bỏ giả thiết gốc H_0 (fail to reject). Dựa trên mẫu dữ liệu quan sát được và giá trị trung bình khoảng cách của mẫu (82.48 inches), chúng ta không thể ủng hộ giả thiết đối rằng khoảng cách trung bình nhào lộn (tổng thể) của tất cả người lớn là lớn hơn 80 inches

Cách 2: dùng khoảng tin cậy để kiểm tra (lần nữa) giả thiết thống kê

mức ý nghĩa (significant level) $\alpha = 0.05 = 5\%$

→ 90% confidence interval (dùng khoảng tin cậy với độ tin cậy 90%)

• trung bình mẫu mean = 82.48

độ lệch chuẩn mẫu std = 15.08

cỡ mẫu (số quan sát) $n = 25$

→ $t^* = 1.711$

$$\bar{X} \pm t^* \frac{S}{\sqrt{n}}$$

$$82.48 \pm 1.711 \times \frac{15.08}{\sqrt{25}}$$

$$82.48 \pm 5.15$$

80 $\in$ (77.33 inches, 87.63 inches)

Khoảng tin cậy này cho ta một khoảng "hợp lý" mà ta nghĩ rằng trung bình tổng thể sẽ nằm trong đó. Toàn bộ khoảng này ko nằm trên 80 nên ta ko thể bác bỏ H_0 và ko thể ủng hộ H_1 (kể trung bình tổng thể $>$ đáng kể 80 inches).

Một vài comments về giả thiết dữ liệu cần có phân phối chuẩn trong ví dụ này của chúng ta:

Chúng ta thấy rằng phân phối của khoảng cách nhào lộn trong dữ liệu của chúng ta bị nghiêng nhiều về phía bên trái hơn + cỡ mẫu không “đủ” lớn (25 nhỏ hơn 30) để dùng định lý giá trị trung tâm xấp xỉ chuẩn. Nếu bạn thấy xấp xỉ chuẩn không tối ưu và hợp lý lắm, thì có thể sử dụng kỹ thuật **kiểm định phi tham số (non-parametric test)** (khi làm việc với ước lượng phi tham số hay kiểm định phi tham số thì không cần giả sử dữ liệu có phân phối gì). Và trong trường hợp của ví dụ chúng ta có thể dùng Wilcoxon Signed Rank test

TỔNG KẾT:

- Kiểm định giả thiết thống kê dùng để kiểm định một giả thiết về tham số tổng thể nào đó mà ta quan tâm (ví dụ, tỷ lệ tổng thể, trung bình tổng thể)
- *Các bước thực hiện kiểm định giả thiết thống kê (hypothesis testing)*
 - Bước 1: Phát biểu giả thiết (giả thiết gốc H_0 và giả thiết đối H_1) và xác định mức ý nghĩa (significant level)
 - Bước 2: Kiểm tra giả thiết của dữ liệu (random sample, xấp xỉ chuẩn), lấy thông tin từ dữ liệu và tính giá trị thống kê kiểm định (test statistic)
 - Bước 3: Chuyển đổi giá trị thống kê kiểm định (test statistic) sang p-value
 - Bước 4: So sánh giá trị p-value với mức ý nghĩa và đưa ra quyết định.

III) Kiểm định giả thiết thống kê cho sự so sánh khác nhau giữa 2 tỷ lệ tổng thể của 2 tổng thể độc lập

Ví dụ vấn đề quan tâm:

Có sự khác nhau đáng kể giữa tỷ lệ tổng thể cha mẹ ở thành thị mà có con trong độ tuổi 6-18 đi học bơi và tỷ lệ cha mẹ ở nông thôn mà có con trong độ tuổi 6-18 đi học bơi hay không ?

Phân tích:

- Tổng thể: cha mẹ ở thành thị có con ở tuổi 6 – 18 (tổng thể 1) và cha mẹ ở nông thôn có con ở tuổi 6 – 18 (tổng thể 2)
- Tham số ta quan tâm: $p_1 - p_2$ trong đó p_1 là tỷ lệ tổng thể 1 và p_2 là tỷ lệ tổng thể 2

Mục đích: Chúng ta *kiểm định* rằng *liệu có sự khác nhau đáng kể* giữa tỷ lệ cha mẹ ở thành thị và nông thôn mà có con trong độ tuổi 6-18 đi học bơi với mức ý nghĩa 10%.

Chú ý: Thực tế khi kiểm định bất kỳ giả thiết thống kê nào, chúng ta nên chọn giả thiết mà ta muốn kiểm định trước khi thu thập dữ liệu để tránh ảnh hưởng đến nhận định giả thiết mà ta muốn kiểm tra.

⊗ Bước 1: Thiết lập giả thiết thống kê

- Giả thiết gốc cần kiểm định
(null hypothesis)

$$H_0: p_1 - p_2 = 0$$

- Giả thiết đối (alternative hypothesis) $H_1: p_1 - p_2 \neq 0$

↑
vì ta muốn tìm hiểu xem tỷ lệ đó có khác nhau đáng kể hay không, không quan tâm đến $p_1 > p_2$ hay $p_2 > p_1$

p_1 và p_2 là tỷ lệ tổng thể của 2 tổng thể.

● Xác định mức ý nghĩa thống kê (significant level)

$$\alpha = 10\% = 0.10$$

⊗ bước 2: kiểm tra dữ liệu và tính giá trị thống kê kiểm định (test statistic)

Dữ liệu khảo sát :

308 cha mẹ ở thành thị mà có con từ 6-18 tuổi được khảo sát và trong đó có 120 cha mẹ có con đi học bơi
247 cha mẹ ở nông thôn mà có con từ 6-18 tuổi được khảo sát và trong đó có 91 cha mẹ có con đi học bơi

Kiểm tra giả thiết của dữ liệu:

- 2 mẫu độc lập với nhau và được thu thập ngẫu nhiên (random samples)
- Cỡ mẫu đủ lớn để có thể xấp xỉ chuẩn thông qua định lý giới hạn trung tâm: có ít nhất 10 người trả lời có và 10 người trả lời không ở mỗi mẫu

↓
kiểm tra

$$\hat{p} = \frac{120 + 91}{308 + 247} = 0.38 \quad \left(\begin{array}{l} \text{tỷ lệ trả lời có từ mẫu} \\ \text{xác suất} \end{array} \right)$$

mẫu 1 : $308 \times 0.38 = 117$; $308 \times (1 - 0.38) = 191$ (> 10 từ cả)

mẫu 2 : $247 \times 0.38 = 94$; $247 \times (1 - 0.38) = 153$

$$Z = \frac{\text{tính giá trị thống kê kiểm định (test statistic)}}{\text{ước lượng tốt nhất} - \text{ước lượng được giả thiết}} = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2 \text{ ở } H_0)}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

|| dùng khi p_1 gần p_2
 ước lượng "sai số" (standard error)

- ước lượng tốt nhất của tham số tổng thể ta quan tâm : $p_1 - p_2$

$$\hat{p}_1 = \frac{120}{308} = \underline{0.39}$$

$$\hat{p}_2 = \frac{91}{247} = \underline{0.37}$$

$$\hat{p}_1 - \hat{p}_2 = 0.02$$

($\hat{p}_1$ gần $\hat{p}_2$)

(tổng thể 1 : thành thị , tổng thể 2 : nông thôn)

- "Sai số" (standard error) = $\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} = \sqrt{0.38(1-0.38)\left(\frac{1}{308} + \frac{1}{247}\right)}$

$$\hat{p} = \frac{120+91}{308+247} = 0.38$$

$$= 0.041$$

$$\Rightarrow Z = \frac{0.02 - 0}{0.041} = 0.48$$

⊗ Chú ý : nếu ta dùng "sai số"

$$(*) = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} = \sqrt{\frac{0.39(1-0.39)}{308} + \frac{0.37(1-0.37)}{247}} \approx 0.041$$

⊗ Nhớ lại cơ sở lý thuyết để xác định ước lượng sai số:

(độc lập) $\hat{p}_1 \sim N\left(p_1, \frac{p_1(1-p_1)}{n_1}\right)$; p_1, p_2 không biết giá trị thực, ta chỉ có thông tin từ dữ liệu quan sát được từ mẫu.

$\hat{p}_2 \sim N\left(p_2, \frac{p_2(1-p_2)}{n_2}\right)$

→ ước lượng xấp xỉ chúng với $\hat{p}_1, \hat{p}_2$ và có công thức (*).


⊗ Hiểu ý nghĩa của giá trị thống kê kiểm định Z-test statistic:

Ước lượng sai khác = ước lượng giả thiết là đúng + $0.48 * \text{"sai số"}$

Quan sát của chúng ta về sự khác nhau giữa 2 tỷ lệ mẫu cách xa giả thiết sai khác giữa tỷ lệ (tổng thể) của hai tổng thể là như nhau (=0) một khoảng cách được ước lượng lớn hơn 0 một khoảng bằng 0.48 lần sai số được ước lượng

⊛ Bước 3 : tính p-value từ Z-test statistic

$$\begin{aligned} Z &\sim N(0,1) \\ p\text{-value} &= 2 \int_{-\infty}^{-0.48} \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{x^2}{2}} dx \\ &= 2 \times \underbrace{0.315614}_{\text{tra bảng}} = 0.63 \end{aligned}$$



⊛ Bước 4 : so sánh p-value và mức ý nghĩa α và đưa ra kết luận.

$$p\text{-value} = 0.63 > \alpha = 0.10 \rightarrow \text{"Không thể bác bỏ } H_0 \text{" (fail to reject)}$$

Kết luận: Dựa vào mẫu dữ liệu quan sát được và thông qua thao tác kiểm định giả thiết, chúng ta không có đủ bằng chứng để bác bỏ (chống đối) lại giả thiết gốc H_0 rằng không có sự khác nhau giữa tỷ lệ 2 tổng thể.

Như vậy, (có thể) không có sự khác biệt đáng kể giữa tỷ lệ cha mẹ ở thành thị và nông thôn có con ở tuổi 6-18 tuổi đi học bơi

IV) Kiểm định giả thiết thống kê về sự khác nhau giữa 2 kỳ vọng (tổng thể) của 2 tổng thể' độc lập.

Vấn đề ta quan tâm: Xem xét tất cả người lớn từ 18-29 tuổi đang sinh sống ở Việt Nam, trung bình chỉ số cân nặng sức khoẻ BMI ở nam giới có **khác nhau đáng kể** so với nữ giới hay không ?

Tổng thể: tất cả người lớn từ 18-29 tuổi đang sinh sống ở Việt Nam

Tham số ta quan tâm: $\mu_1 - \mu_2$

trong đó μ_1 là trung bình chỉ số BMI (kg/m^2) của nam giới và μ_2 là trung bình chỉ số BMI (kg/m^2) của nữ giới.

Các bước kiểm định một giả thiết thống kê:

- Bước 1: Xác định giả thiết gốc và giả thiết đối, xác định mức ý nghĩa
- Bước 2: Kiểm tra dữ liệu, kiểm tra giả thiết của dữ liệu thu thập, tính giá trị thống kê kiểm định (test statistic)
- Bước 3: Tính giá trị p (p-value) từ giá trị thống kê kiểm định (z-test statistic hay t-test statistic)
- Bước 4: So sánh giá trị p với mức ý nghĩa và đưa ra kết luận về giả thiết gốc

⊗ Bước 1 : Xác định giả thiết gốc và giả thiết đối + xác định mức ý nghĩa


giả thiết gốc $H_0 : \mu_1 = \mu_2 \quad (\mu_1 - \mu_2 = 0)$

giả thiết đối $H_1 : \mu_1 \neq \mu_2 \quad (\mu_1 - \mu_2 \neq 0)$

Mức ý nghĩa : $\alpha = 5\% = 0.05$



⊗ Bước 2 : kiểm tra dữ liệu, kiểm tra giả thiết dữ liệu và tính giá trị thống kê kiểm định (test statistic)

Gender	BMI	Race	Age 18-29		Male	Female
1	19.9	1	1	Mean	23.57	22.83
2	17.0	1	1	St. Dev.	6.24	6.43
2	26.7	1	1	Min	12.5	12.4
1	25.6	1	1	Max	44.9	48.8
...	...	...	...	n	258	239





Kiểm tra giả thiết của dữ liệu gồm có:

- Dữ liệu có thu thập ngẫu nhiên không (random sample): đại diện được tổng thể, xác suất người được chọn để khảo sát bằng nhau
- 2 mẫu thu thập có độc lập không
- Các quan sát độc lập của ta $X_1, X_2, \dots, X_n$ (tương ứng các biến ngẫu nhiên) có phân phối chuẩn không, hoặc cả 2 tổng thể có phân phối chuẩn không, hoặc dữ liệu đủ lớn để xấp xỉ chuẩn không.



histogram



Q-Q plot

cỡ mẫu của
cả 2 mẫu
đủ lớn để
xấp xỉ chuẩn
cho giá trị
trung bình mẫu

thì giá trị thống kê kiểm định (test statistic)

$$H_0 : \mu_1 - \mu_2 = 0$$

$$H_1 : \mu_1 - \mu_2 \neq 0$$

Ước lượng tối nhất của $\mu_1 - \mu_2$ là $\hat{\mu}_1 - \hat{\mu}_2 = 23.57 - 22.83 = 0.74$ (kg/m²)

↑ ↑
trung bình trung bình
mẫu 1 mẫu 2

Sự khác nhau giữa hai trung bình mẫu của chúng ta là 0.74 có khác xa 0?

Chúng ta đo khoảng cách bao xa từ tham số thống kê của mẫu đến tham số thống kê của tổng thể mà được giả thiết thông qua ước lượng "sai số của tham số (standard errors)". Khoảng cách giá trị tham số mẫu càng xa giá trị tham số tổng thể thì chúng ta càng ít tin cậy vào giả thiết gốc.

Công thức chung:

$$\text{giá trị test statistic} = \frac{\text{ước lượng tối nhất} - \text{giá trị được giả thiết ở giả thiết gốc } H_0}{\text{ước lượng "sai số của tham số" (standard error)}}$$

TH₁ : phương sai 2 tổng thể bằng nhau (TH đặc biệt)


$$\text{test statistic } Z = \frac{(\bar{X}_1 - \bar{X}_2) - 0}{\sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = \frac{(23.57 - 22.83) - 0}{\sqrt{\frac{257 \times 6.24^2 + 238 \times 6.43^2}{258 + 239 - 2}} \sqrt{\frac{1}{258} + \frac{1}{239}}}$$

TH₂: TH tổng quát

$$\text{test statistic } Z = \frac{(\bar{X}_1 - \bar{X}_2) - 0}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

= 1.30 Sự khác nhau giữa 2 trung bình mẫu của chúng ta lớn hơn sự khác nhau giữa 2 trung bình tổng thể (0 kg/m²) mà ta giả thiết 1.30 lần "sai số của tham số" (standard error)

	Male	Female
Mean	23.57	22.83
St. Dev.	6.24	6.43
Min	12.5	12.4
Max	44.9	48.8
n	258	239




→ có thể giả sử phg sai bằng nhau dùng công thức TH đặc biệt

⊗ Bước 3: tính giá trị p (p-value) từ giá trị test statistic

Nếu giả thiết gốc $H_0: \mu_1 - \mu_2 = 0$ là đúng, thì giá trị thống kê kiểm định (test statistic) đủ “bất thường, khác lạ” để ta bác bỏ giả thiết gốc hay không?

Giá trị p (p-value): khi ta giả sử giả thiết gốc H_0 là đúng, thì giá trị p (p-value) này chính là xác suất của biến cố quan sát được giá trị thống kê kiểm định $Z = 1.30$ và những biến cố tương tự mà “hiếm tương đương” VÀ “hiếm hơn” (more extreme)



$Z \sim N(0,1)$ (nhớ lại tại sao)

$$\begin{aligned} p\text{-value} &= \text{xác suất phần màu xanh} \\ &= 2 \int_{-\infty}^{-1.3} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \\ &= 2 \times 0.096801 = 0.1936 \end{aligned}$$

⊛ Bước 4: so sánh p-value với mức ý nghĩa và đưa ra kết luận về giả thiết gốc H_0 .

p-value = 0.19 > mức ý nghĩa $\alpha = 0.05 \rightarrow$ "không thể bác bỏ" H_0
(fail to reject)

Bằng chứng của chúng ta (dữ liệu quan sát được và thông qua quá trình kiểm định thống kê) không đủ mạnh để chống lại giả thiết gốc. Do đó, ta không thể bác bỏ giả thiết gốc. Nghĩa là, chúng ta không thể ủng hộ rằng có sự khác nhau đáng kể giữa giá trị trung bình chỉ số sức khỏe BMI của tất cả nam và tất cả nữ độ tuổi từ 18 đến 29 mà đang sinh sống ở VN.

Chú ý Cách 2: dựa vào khoảng tin cậy.

xem file "khoảng tin cậy tiếp theo"

khoảng tin cậy của $\mu_1 - \mu_2$ với độ tin cậy 95% là

$(-0.37, 1.85) \ni 0 \rightarrow$ không thể ủng hộ rằng có sự khác nhau đáng kể giữa trung bình tổng thể của 2 tổng thể độc lập.

(mức ý nghĩa 5%)